Análisis exploratorio de datos

Dónde se sitúa el EDA en Data Science y en IA

Un proyecto de ciencia de datos utiliza información para responder una pregunta. Puede terminar en una descripción, una explicación o un sistema que haga predicciones. En los proyectos de inteligencia artificial que aprenden de datos, entender esos datos es una parte del trabajo previo al entrenamiento.

El **análisis exploratorio de datos**, conocido como **EDA**, permite conocer la estructura del conjunto, revisar su calidad y estudiar cómo se distribuyen y se relacionan sus variables. Su finalidad es fundamentar la interpretación y las decisiones posteriores.

Etapa del proyecto	Propósito
Definir el problema y obtener los datos	Precisar qué queremos saber, qué población interesa y de dónde procede la información.
Revisar, explorar y limpiar	Conocer los datos, detectar problemas y examinar patrones. Aquí se sitúa el EDA.
Preparar y entrenar, si es necesario	Adaptar las entradas al modelo y ajustar su comportamiento con los datos de entrenamiento.
Evaluar y comunicar	Comprobar los resultados, explicar sus límites y valorar si responden a la pregunta inicial.
Utilizar y revisar	Si se implanta un sistema, comprobar que sigue siendo útil cuando cambian los datos.

Un proceso que se revisa a medida que avanza

La exploración y la limpieza se influyen mutuamente: un gráfico puede revelar un error y una corrección puede cambiar la distribución. El EDA no es una lista rígida de gráficos ni una fase que impida volver atrás.

Un análisis descriptivo puede estudiar el conjunto disponible y terminar sin ningún modelo. En un proyecto predictivo, el conjunto de prueba debe reservarse antes de tomar decisiones de preparación o de modelado basadas en una exploración detallada.

1. Definir la pregunta y comprender los datos

Antes de interpretar una tabla, necesitamos conocer qué representa cada fila, qué significa cada columna y para qué queremos utilizar la información. Un resultado correcto desde el punto de vista numérico puede ser irrelevante si responde a otra pregunta.

Población, muestra y unidad de observación

La **población** es el conjunto completo que queremos estudiar. La **muestra** es la parte de esa población de la que disponemos de datos. Tener muchas filas no garantiza que la muestra sea representativa: puede excluir ciertos grupos, periodos o situaciones.

La **unidad de observación** es aquello que representa una fila: una persona, una vivienda, una visita o una transacción. Varias filas de una misma persona no equivalen a varias personas independientes.

Tipo de variable	Qué representa	Ejemplo conceptual
Numérica continua	Una medida que puede tomar valores en un intervalo.	Duración o superficie.
Numérica discreta	Un recuento con valores separados.	Cantidad de habitaciones.
Categórica nominal	Grupos sin orden natural.	Zona o tipo de vivienda.
Categórica ordinal	Categorías que tienen un orden.	Satisfacción baja, media o alta.
Temporal	Un momento o periodo.	Fecha de una observación.

Un identificador puede contener números y seguir siendo una etiqueta. Su media no suele describir una propiedad de los casos. También debemos conocer unidades, periodo de recogida y significado de las ausencias.

Objetivo del análisis

Describir una distribución, comparar grupos y examinar una relación son preguntas distintas. En un proyecto predictivo, la variable objetivo es lo que se quiere estimar; las variables de entrada son las características conocidas al hacer esa estimación. Un EDA descriptivo no necesita obligatoriamente una variable objetivo.

2. Primera revisión y calidad de los datos

La primera revisión busca entender la estructura y detectar señales de problemas. Todavía no consiste en corregir todo lo que parezca extraño. Observar una anomalía y decidir qué significa son pasos diferentes.

Aspecto que se revisa	Por qué importa
Cantidad de filas y columnas	Delimita la información disponible y ayuda a detectar archivos incompletos o estructuras inesperadas.
Significado y unidades	Evita mezclar medidas distintas o interpretar códigos como cantidades.
Tipos y formatos	Permite advertir números tratados como texto, fechas ambiguas o categorías inconsistentes.
Valores ausentes	Muestra qué información se desconoce y si la ausencia se concentra en algún grupo.
Repeticiones	Permite distinguir copias accidentales de observaciones repetidas que pueden ser legítimas.
Rangos y coherencia	Ayuda a localizar valores imposibles y contradicciones entre campos.

La calidad depende del contexto

Un cero puede ser válido o puede encubrir una ausencia. Una antigüedad de cero años puede representar una vivienda nueva. En cambio, una superficie negativa incumple la definición de esa medida. Las reglas deben proceder del significado de los datos.

Dos filas iguales pueden ser una copia accidental, pero dos observaciones de una misma entidad en momentos diferentes pueden ser correctas. Eliminar datos sin distinguir ambos casos cambia el fenómeno que estamos estudiando.

Qué debe quedar claro

La procedencia, el alcance y las limitaciones del conjunto deben conocerse antes de comparar resultados. La revisión inicial permite formular preguntas para la limpieza y decidir qué aspectos requieren una exploración más profunda.

3. Qué significa limpiar los datos

La limpieza consiste en resolver problemas de representación, validez o coherencia que afectarían al análisis. No busca conseguir una distribución bonita ni eliminar casos que contradigan lo que esperábamos encontrar.

Errores e inconsistencias

Etiquetas equivalentes escritas de varias formas pueden unificarse. Una unidad incorrecta exige comprobar la fuente. Un número imposible debe investigarse antes de sustituirlo. Cuando no conocemos el valor correcto, marcarlo como ausente es distinto de recuperarlo.

Valores ausentes

Una ausencia puede deberse a una medición perdida, una pregunta no respondida o un campo que no se aplica. El porcentaje de nulos ayuda a dimensionar el problema, pero no explica su causa. Importa también qué casos y grupos se ven afectados.

Tratamiento posible	Qué implica
Recuperar desde la fuente	Utilizar un valor que pueda verificarse.
Excluir de un análisis	Trabajar con los casos que tienen los datos necesarios; puede cambiar la composición de la muestra.
Imputar	Asignar un valor estimado. La información no se convierte por ello en una observación real.
Mantener la ausencia	Conservar lo desconocido mientras se investiga o cuando el análisis admite esa situación.

La imputación con una media o mediana puede modificar la dispersión y las relaciones. Eliminar filas también puede introducir sesgos. No existe una regla universal que obligue a aplicar siempre el mismo tratamiento.

Valor extremo y dato incorrecto

Un valor extremo es poco habitual respecto al conjunto; un error incumple una regla o procede de una medición incorrecta. Un caso real puede ser extremo. Los gráficos ayudan a señalarlo, pero no deciden automáticamente que deba eliminarse.

4. Conceptos para interpretar las distribuciones

La **distribución** describe cómo se reparten los valores de una variable: dónde se concentran, cuánto varían y qué formas aparecen. Los resúmenes numéricos y los gráficos muestran aspectos complementarios de esa distribución.

Concepto	Significado
Frecuencia	Cantidad de observaciones de un valor, una categoría o un intervalo. La frecuencia relativa expresa su proporción sobre el total considerado.
Media	Suma de los valores dividida entre su cantidad. Los valores muy grandes o pequeños pueden desplazarla.
Mediana	Valor central de los datos ordenados. Es el percentil 50; con una cantidad par suele obtenerse promediando los dos valores centrales.
Moda	Valor o categoría más frecuente. Puede haber varios empatados. Un pico de histograma corresponde a un intervalo y no identifica necesariamente la moda exacta.
Dispersión	Grado de variación de los datos. Puede describirse con el rango, el rango intercuartílico o la desviación estándar.
Cuartiles	Q1 es el percentil 25 y Q3 el percentil 75. Delimitan aproximadamente la mitad central de los datos.

Forma de la distribución

Una distribución aproximadamente simétrica tiene un reparto parecido a ambos lados de su centro. Una distribución asimétrica presenta una cola más prolongada hacia un lado. También pueden aparecer varias concentraciones o grandes espacios con pocos datos.

La media y la mediana pueden coincidir en distribuciones muy diferentes. Por eso, un mismo centro no basta para afirmar que dos grupos se comportan igual. La forma, la dispersión y el tamaño de cada grupo también importan.

Los percentiles y cuartiles pueden variar ligeramente según el método de cálculo, especialmente con muestras pequeñas o muchos valores repetidos. Su lectura debe ser aproximada, no una división exacta de personas en todos los casos.

5. Elegir y leer un gráfico de EDA

Un gráfico debe responder a una pregunta identificable. La elección depende del tipo de variables y del aspecto que queremos estudiar. Antes de interpretar la forma, debemos comprobar qué representan los ejes, las unidades, las categorías y la escala.

Pregunta	Gráfico inicial	Información principal
¿Cómo se reparte una medida?	Histograma	Forma y concentración de los valores.
¿Cuál es su centro y su dispersión?	Boxplot	Mediana, cuartiles y posibles extremos.
¿Cuántos casos hay de cada categoría?	Barras	Frecuencias o porcentajes.
¿Cómo se relacionan dos medidas?	Dispersión	Patrón de una nube de puntos.
¿Qué valores destacan en una tabla?	Mapa de calor	Magnitud o signo mediante colores.

Una variable o varias

El análisis **univariante** estudia una variable. El **bivariante** examina dos, y el **multivariante** incorpora más de dos. Un gráfico de dispersión con colores para distinguir grupos ya combina dos medidas y una categoría.

Escalas y comparaciones

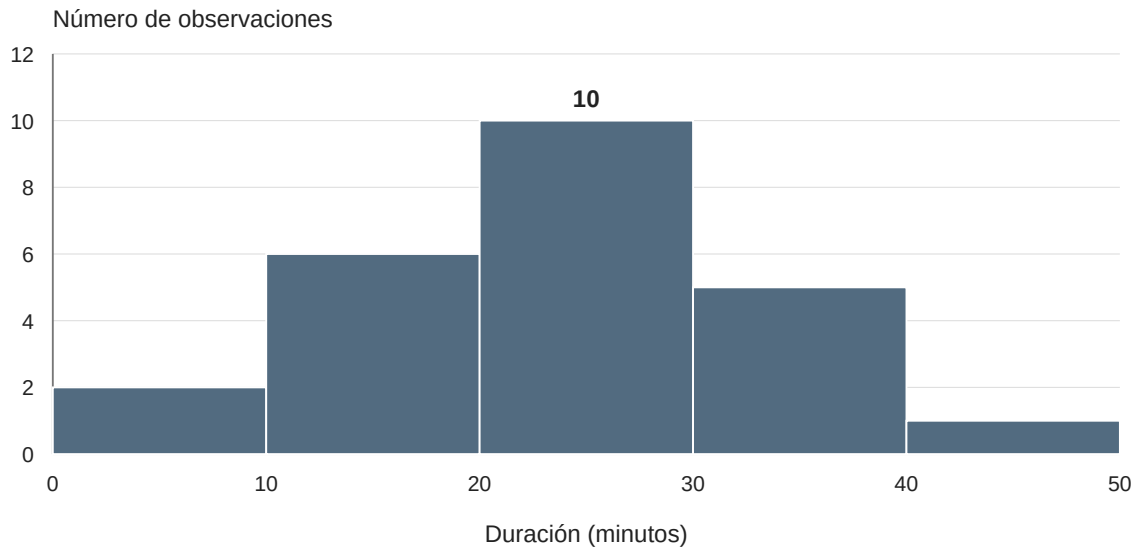
Para comparar grupos, las escalas deben ser compatibles. Los recuentos dependen del número de casos; los porcentajes facilitan algunas comparaciones, pero deben indicar sobre qué total se calculan. El color necesita una leyenda cuando representa una magnitud o categoría.

En barras de frecuencias, el eje de recuento debe partir de cero para que la longitud conserve su significado. En una dispersión o un boxplot puede usarse otro rango si se indica claramente y no se ocultan aspectos relevantes.

Los esquemas de las páginas siguientes ilustran cómo se leen los gráficos. No representan resultados de un estudio real.

6. Histograma: cómo es y para qué se utiliza

Un **histograma** representa la distribución de una variable numérica agrupando sus valores en intervalos. Cada rectángulo corresponde a un intervalo; en su forma más sencilla, la altura indica cuántas observaciones contiene.



Sus partes

El eje horizontal muestra los valores y sus unidades. El eje vertical indica frecuencia, porcentaje o densidad, según la variante. Los rectángulos suelen tocarse porque representan intervalos contiguos de una misma escala numérica.

En el esquema, la barra entre 20 y 30 minutos reúne diez observaciones. No significa que existan diez valores iguales a 25 ni permite recuperar las duraciones exactas de ese intervalo.

Para qué sirve y cómo se utiliza

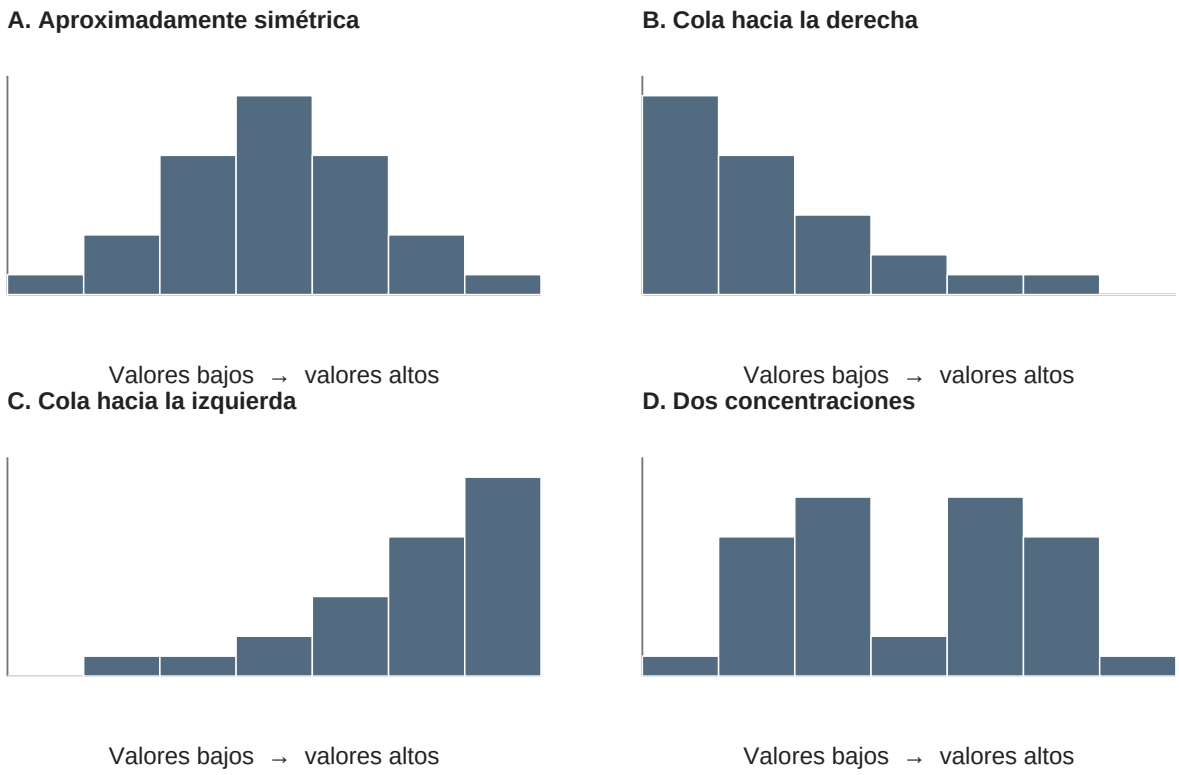
Permite localizar concentraciones, colas, huecos y posibles extremos. Se utiliza al estudiar la forma de una medida y al valorar si un resumen como la media describe bien el conjunto. Para comparar histogramas, deben mantenerse intervalos y escalas comparables.

El número y la anchura de los intervalos afectan al aspecto: pocos intervalos pueden ocultar estructura; demasiados pueden producir irregularidades difíciles de interpretar. También importa dónde comienzan sus límites.

Frecuencia, porcentaje y densidad

Con intervalos iguales, la altura puede representar recuentos o proporciones. Si las anchuras son distintas, la altura debe ajustarse por la anchura para que el área represente la frecuencia. En un histograma de densidad, el área total es 1: la altura por sí sola no es un porcentaje.

7. Histograma: cómo interpretar su forma



Centro, dispersión y colas

A. Una forma aproximadamente simétrica sugiere un reparto parecido a ambos lados del centro. No demuestra por sí sola que la distribución sea normal.

B. Una cola hacia la derecha indica que algunos valores altos se prolongan más allá de la concentración principal. Esa cola puede desplazar la media hacia arriba.

C. Una cola hacia la izquierda indica que algunos valores bajos se alejan de la concentración principal. La dirección de la cola determina el nombre de la asimetría, no el lado con la barra más alta.

D. Dos concentraciones sugieren una posible mezcla de situaciones o grupos. Hay que comprobar si el patrón se mantiene con otros intervalos y si el contexto ofrece una explicación.

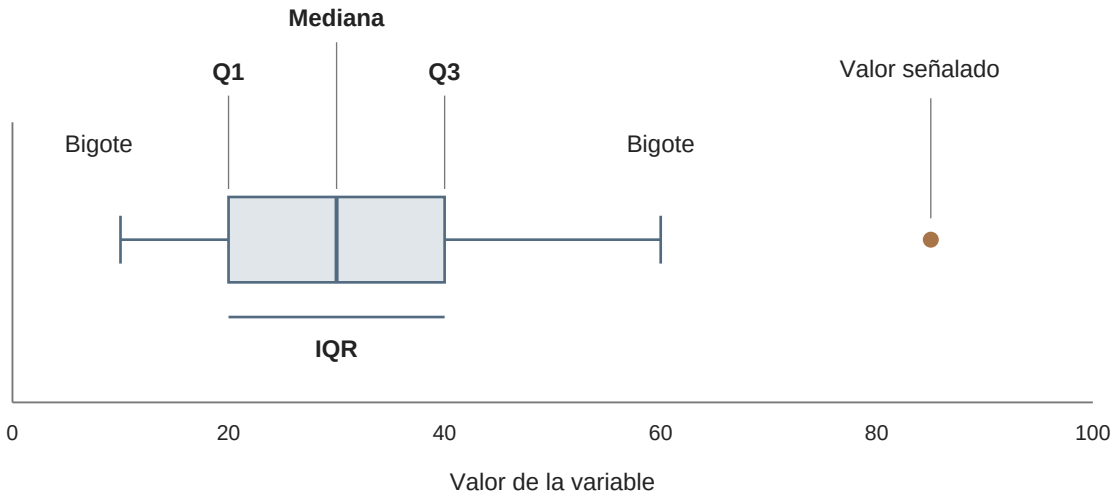
Qué conviene mirar y qué no permite concluir

La lectura debe considerar dónde se concentran los valores, cuánto ocupan en la escala, qué colas aparecen y si existen zonas con pocas observaciones. Un intervalo aislado puede señalar casos que revisar, pero no demuestra que sean errores.

Un histograma pierde el orden de las observaciones y sus valores exactos. No muestra la relación con otra variable ni una evolución temporal. Dos grupos pueden tener histogramas parecidos y diferir en otros aspectos. La apariencia depende de la muestra y de los intervalos elegidos.

8. Boxplot: caja, mediana, bigotes y puntos

El **boxplot**, o diagrama de caja y bigotes, resume el centro y la dispersión de una variable numérica. Puede dibujarse horizontal o verticalmente: cambia la orientación, pero no el significado de sus partes.



Elemento	Cómo se interpreta
Caja	Se extiende de Q1 a Q3 y reúne aproximadamente el 50 % central. Su longitud en el eje numérico es el rango intercuartílico: IQR = Q3 - Q1.
Línea interior	Marca la mediana. No representa la media, salvo que se añada expresamente otro símbolo para ella.
Bigotes	En la convención habitual de Tukey llegan a los valores observados más extremos que quedan dentro de los límites de 1,5 veces el IQR.
Puntos separados	Señalan observaciones situadas fuera de esos límites. Son posibles valores atípicos, no errores demostrados.

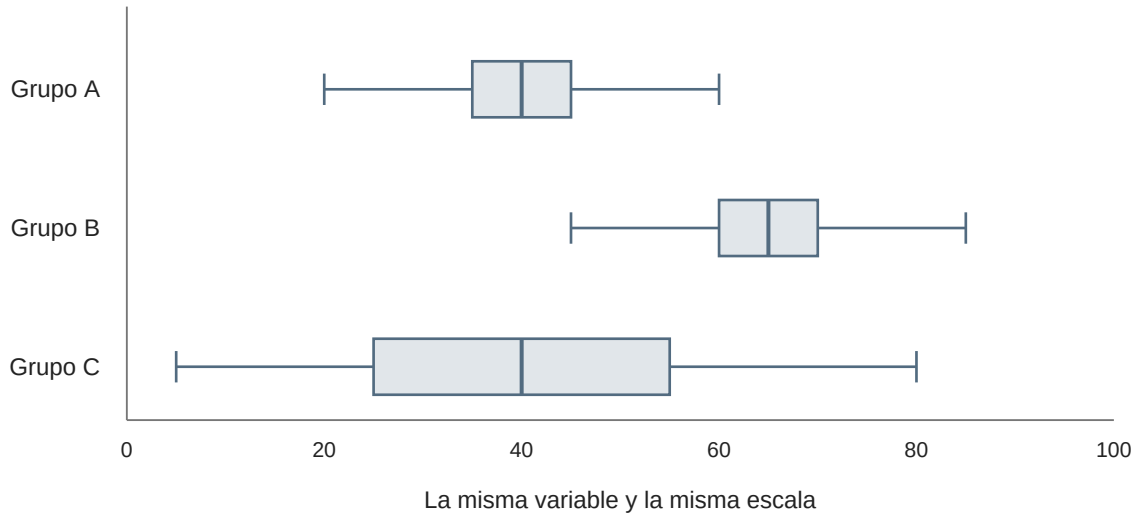
Límites y bigotes no son lo mismo

Los límites de referencia son **Q1 - 1,5 × IQR** y **Q3 + 1,5 × IQR**. No tienen por qué coincidir con observaciones. Los extremos de los bigotes sí corresponden a valores observados dentro de ellos.

En el esquema, Q1 vale 20 y Q3 vale 40: el IQR es 20 y el límite superior, 70. El bigote termina en 60 porque es el mayor valor observado dentro del límite. El punto de 85 queda señalado. Existen otras convenciones de boxplot; siempre hay que conocer cuál se utiliza.

9. Boxplot: comparar distribuciones entre grupos

Varios boxplots sobre la misma escala permiten comparar una medida entre categorías. Sirven para examinar diferencias de posición, de dispersión central y de extremos sin representar cada dato individualmente.



La misma variable y la misma escala

Cómo se lee la comparación

El **grupo B** tiene una mediana más alta que A y C. Esto describe una diferencia en el centro de las distribuciones, no que todas sus observaciones sean mayores que todas las de los otros grupos.

Los **grupos A y C** comparten mediana, pero C tiene una caja más extensa: su mitad central está más dispersa. Dos grupos pueden tener el mismo valor central y una variabilidad distinta.

Los bigotes y los puntos separados aportan información sobre las zonas exteriores de la distribución. Una mediana descentrada en la caja o bigotes desiguales puede sugerir asimetría, que conviene contrastar con un histograma.

Límites de este resumen

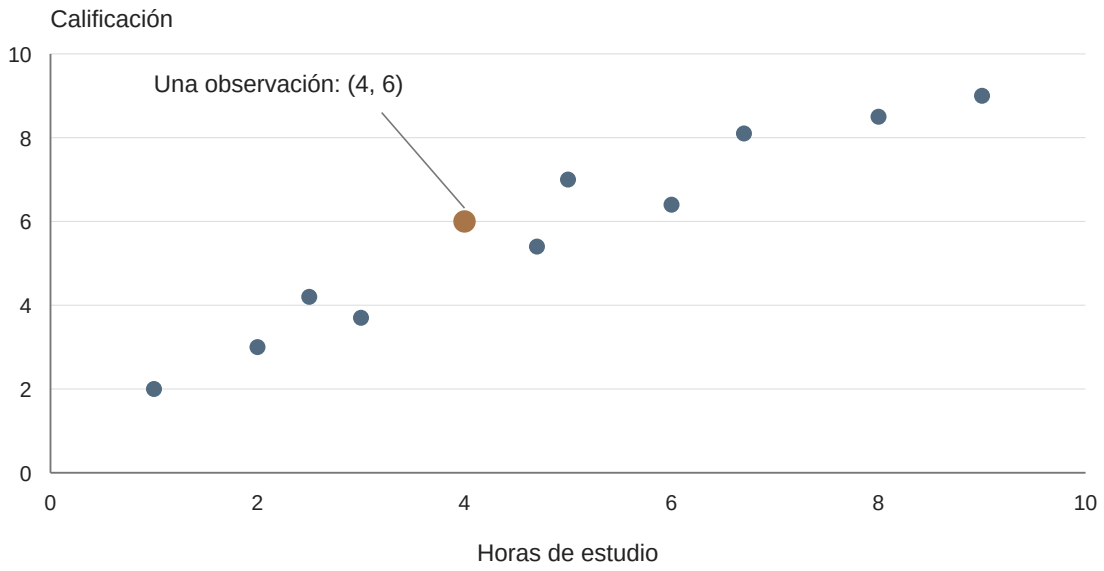
El boxplot no muestra bien cuántas concentraciones existen. Distribuciones distintas pueden compartir cuartiles parecidos. Tampoco permite reconstruir todos los datos ni saber cuántas observaciones coinciden en un mismo valor.

El grosor de las cajas no indica el tamaño del grupo salvo que esa convención se declare. Con cajas de grosor fijo, un grupo pequeño puede parecer tan visible como uno grande. Por eso hay que conocer el número de casos de cada categoría.

El solapamiento de cajas no sustituye a una prueba de diferencias entre poblaciones. El gráfico describe los datos disponibles; no demuestra causalidad ni decide por sí solo si una diferencia es estadísticamente significativa.

10. Dispersión: una observación en cada punto

Un **gráfico de dispersión** representa pares de valores numéricos. Cada punto corresponde a una misma unidad observada: su posición horizontal indica el valor de X y su posición vertical, el de Y.



Cómo es y para qué sirve

En el esquema, el punto destacado representa una observación con cuatro horas de estudio y una calificación de seis. Las dos coordenadas pertenecen al mismo caso; mezclar medidas de personas distintas no representaría esa relación.

La nube permite examinar dirección, forma, dispersión, agrupaciones y puntos alejados. Se utiliza cuando queremos saber si dos medidas cambian de manera asociada y si esa asociación es parecida en todo el rango.

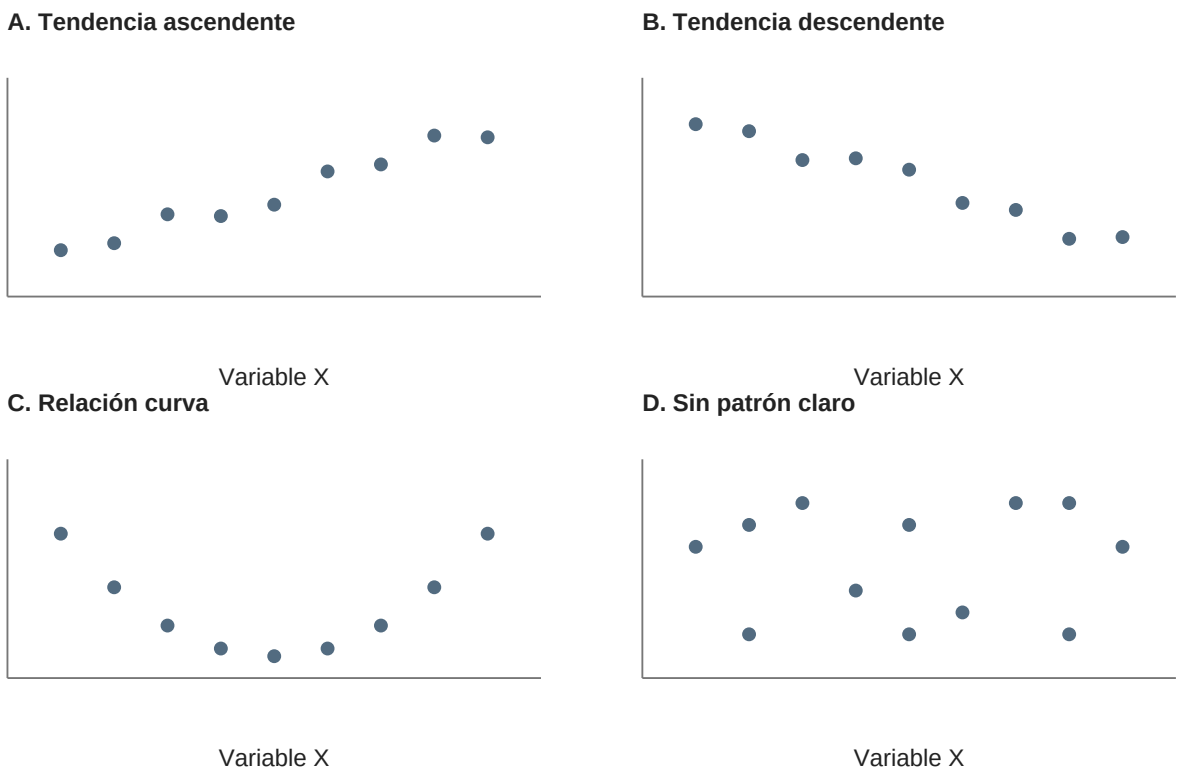
Cómo se utiliza

Se asigna una variable a cada eje y se indican sus unidades. A menudo se coloca en X una característica que interesa relacionar con Y, pero la elección del eje no demuestra que X cause Y. Los puntos no se unen si no existe un orden o una secuencia que justifique esas conexiones.

Para incorporar una categoría se pueden usar colores o símbolos. La leyenda debe permitir identificar los grupos. Cuando muchos puntos se superponen, una zona oscura puede ocultar numerosas observaciones; el tamaño del punto y la transparencia influyen en su visibilidad.

La comparación entre varias nubes exige revisar sus escalas y el rango observado. Un patrón que parece fuerte en una vista estrecha puede ser parte de una estructura más compleja.

11. Dispersión: interpretar patrones y límites



A. Tendencia ascendente: valores altos de X tienden a acompañarse de valores altos de Y. **B. Tendencia descendente:** cuando X aumenta, Y tiende a disminuir.

C. Relación curva: existe una estructura, aunque no se resuma bien mediante una asociación lineal. **D. Sin patrón claro:** el gráfico no muestra una relación evidente en el rango disponible; eso no demuestra independencia en cualquier situación.

Forma y dispersión alrededor del patrón

Una nube estrecha alrededor de una forma sugiere una asociación más definida que una nube muy dispersa. Una forma de abanico indica que la variación vertical cambia según el valor de X. Los grupos separados pueden corresponder a categorías o situaciones diferentes.

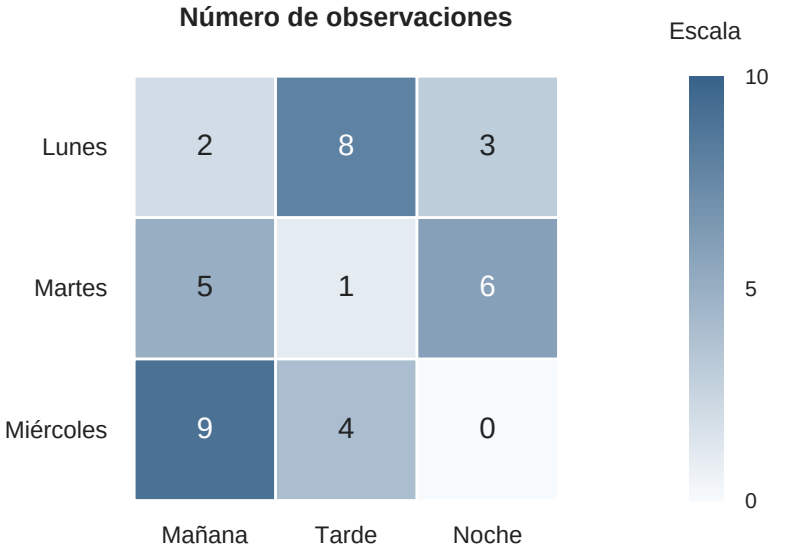
Un punto aislado debe investigarse. Puede ser un caso real, un error o una combinación poco frecuente. Algunos extremos pueden influir mucho en un resumen numérico de la relación; por eso conviene mirar la nube además del coeficiente de correlación.

Asociación y causalidad

Que dos variables cambien juntas no demuestra que una produzca el cambio de la otra. Un tercer factor puede influir en ambas, y la selección de los casos también puede generar patrones. Una gráfica ayuda a formular hipótesis; demostrar causas requiere un planteamiento adicional.

12. Mapa de calor: una tabla representada con colores

Un **mapa de calor** organiza valores en una cuadrícula. Las filas y columnas identifican variables, categorías o momentos. Cada celda representa una combinación, y su color codifica una magnitud o un signo.



Cómo se lee

Primero se comprueba qué representan las filas y las columnas. Después se identifica la magnitud de la leyenda: pueden ser recuentos, porcentajes, medias, correlaciones u otro valor. El color no tiene un significado universal.

En este esquema de recuentos, el miércoles por la mañana tiene nueve observaciones y el martes por la tarde, una. La escala más oscura indica un recuento mayor. El cero de la noche del miércoles es un valor conocido, no un dato ausente.

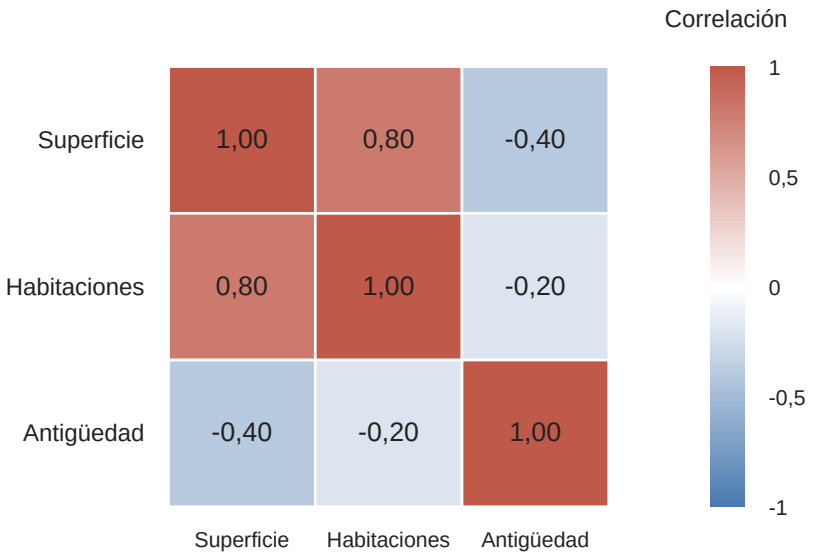
Para qué se usa y qué hay que cuidar

Sirve para localizar concentraciones, contrastes y patrones que costaría reconocer en una tabla extensa. Un mapa de frecuencias entre categorías responde a una pregunta distinta de uno de porcentajes o de correlaciones.

Una escala **secuencial** sirve para magnitudes que van de bajas a altas. Una escala **divergente** distingue valores a ambos lados de una referencia, como cero. Un hueco o un color especial para ausencias debe explicarse. No se debe interpretar una celda vacía como cero sin comprobar la leyenda.

13. Mapa de calor de correlaciones

Una matriz de correlaciones compara variables numéricas por pares. Con **Pearson**, cada coeficiente resume la dirección y la intensidad de una relación lineal. El mapa de calor representa esos coeficientes con una escala de -1 a 1.



Esquema ilustrativo de una matriz de Pearson

Cómo interpretar los valores y los colores

Un valor cercano a **1** indica una asociación lineal positiva fuerte; uno cercano a **-1**, una negativa fuerte. Cerca de **0** significa poca asociación lineal. En el esquema, superficie y habitaciones tienen 0,80; superficie y antigüedad, -0,40. No son resultados de un estudio real.

La diagonal vale 1 cuando una variable con variación se compara consigo misma. La matriz es simétrica: la relación de A con B es la misma que la de B con A. Los dos triángulos repiten la misma información.

Qué permite y qué no permite concluir

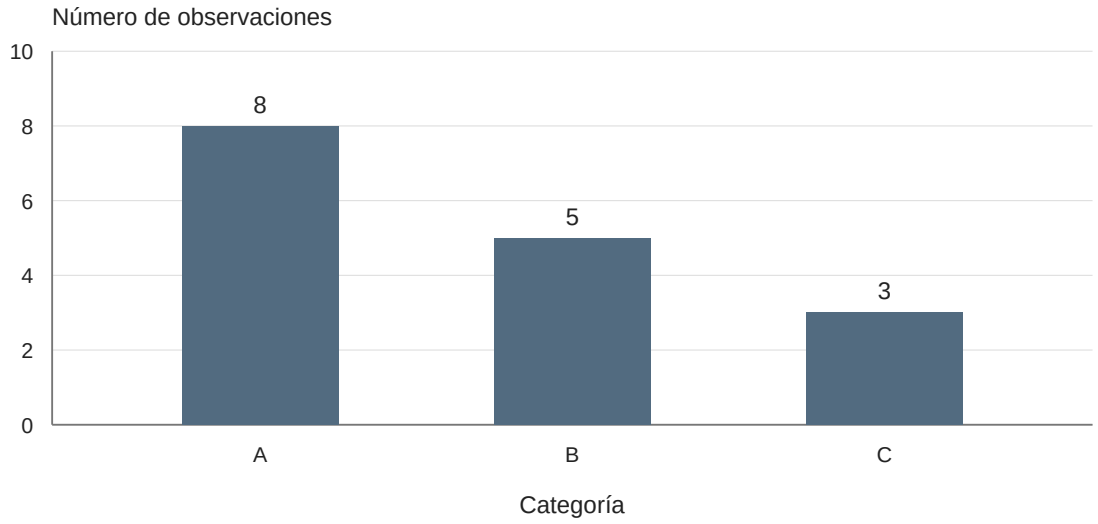
Facilita localizar asociaciones y posibles redundancias entre medidas. No demuestra causalidad ni basta para decidir qué variable es importante para cualquier objetivo. Una relación curva puede presentar un Pearson próximo a cero; un extremo puede alterar mucho el coeficiente.

Los colores solo tienen sentido junto a su escala. Para comparar matrices hay que mantener el mismo rango de colores y conocer qué observaciones se usaron. Si hay ausencias, distintos pares pueden usar cantidades diferentes de casos.

Una variable constante no tiene un Pearson definido con otras, porque su desviación es cero. Un valor no calculable no debe confundirse con una correlación cero. Tampoco es necesario igualar las unidades para calcular Pearson: los cambios positivos de escala no lo alteran.

14. Gráfico de barras y su diferencia con el histograma

Un **gráfico de barras** compara categorías. Cada barra corresponde a una categoría identificada por una etiqueta. Su longitud representa una cantidad especificada: frecuencia, porcentaje u otro resumen.



Para qué sirve y cómo se utiliza

Permite ver qué categorías son más frecuentes, si hay grupos poco representados y cómo se reparte una variable cualitativa. El orden puede ser natural en categorías ordinales o elegirse para facilitar la comparación en categorías nominales.

En el esquema, A tiene ocho observaciones, B cinco y C tres. Las barras están separadas porque representan grupos distintos. El espacio entre categorías no significa una distancia numérica entre ellas.

Aspecto	Barras	Histograma
Qué representa cada rectángulo	Una categoría.	Un intervalo numérico.
Orden	Depende de las categorías y del propósito.	Lo determina la escala numérica.
Separación	Suele haber espacio entre barras.	Los intervalos contiguos suelen tocarse.
Lectura principal	Comparar cantidades entre grupos.	Estudiar la forma de una distribución.

Cuando los grupos tienen tamaños diferentes, los porcentajes pueden ayudar a comparar composiciones. Debe indicarse si se calculan sobre todo el conjunto o dentro de cada grupo. Una barra de media no muestra la dispersión: para comparar distribuciones conviene añadir otra representación, como el boxplot.

15. Relacionar variables sin perder el contexto

Después de comprender cada variable por separado, el EDA estudia relaciones. El tipo de variables determina qué comparación tiene sentido y qué representa cada elemento del gráfico.

Variables	Qué se estudia	Representación habitual
Numérica y numérica	Forma, dirección y dispersión de la asociación.	Dispersión; una correlación puede resumir la parte lineal.
Categórica y numérica	Cómo se distribuye la medida en cada grupo.	Boxplots sobre una escala común.
Categórica y categórica	Frecuencias o proporciones de combinaciones.	Tabla de contingencia, barras agrupadas o mapa de calor.

Incorporar una tercera variable

Distinguir grupos por color o separar un gráfico en paneles permite observar si un patrón global aparece también dentro de cada grupo. Una asociación agregada puede cambiar e incluso invertirse al considerar una variable que separa situaciones diferentes.

Por ejemplo, comparar precios entre zonas sin considerar las superficies describe la diferencia de los anuncios disponibles, pero no identifica un efecto exclusivo de la zona. Las características de los grupos pueden estar mezcladas en la comparación.

Comparar con criterio

Las unidades, el periodo y la definición de cada variable deben coincidir. También hay que conocer los tamaños de los grupos y cuántos casos se excluyeron por ausencias. Un porcentaje alto en un grupo muy pequeño no tiene el mismo respaldo descriptivo que uno basado en muchos casos.

La exploración puede sugerir preguntas nuevas, pero no debe convertir cada diferencia visual en un hallazgo demostrado. Cuantas más comparaciones se buscan, más fácil es encontrar patrones casuales. La explicación debe distinguir lo observado de lo que todavía es una hipótesis.

16. Conclusiones y límites del EDA

El resultado del EDA es una descripción razonada de los datos y de sus límites. Los gráficos son evidencias para esa explicación. Debe quedar claro qué se ha observado, a qué casos se refiere y qué cuestiones siguen abiertas.

Qué debe contener una conclusión

La conclusión identifica los patrones relevantes, las limitaciones de calidad y las decisiones justificadas. Si se han excluido casos o estimado valores ausentes, debe explicar cómo afecta eso a la interpretación. Un patrón no observado no equivale siempre a demostrar su ausencia.

Una formulación descriptiva puede indicar que un grupo presenta una mediana mayor o que dos variables muestran una asociación ascendente. Afirmar que una característica causa la diferencia exige evidencia adicional al gráfico.

Muestra, población y generalización

El EDA describe el conjunto disponible. Para extender las conclusiones a una población mayor importan el diseño de la recogida, la representatividad y el contexto. Un conjunto sesgado sigue estando sesgado aunque sus gráficos sean claros y sus cálculos correctos.

Los datos también tienen un momento de validez: un patrón de un periodo puede cambiar después. Las medidas y categorías deben mantener su significado para que las comparaciones sean interpretables.

Su relación con un proyecto predictivo

En un proyecto predictivo, el EDA ayuda a comprender las entradas y a fundamentar su preparación. Las decisiones se apoyan en entrenamiento; los datos de prueba se reservan para valorar el resultado final. Utilizar prueba repetidamente para elegir cambios incorpora información de evaluación al desarrollo.

Los valores de imputación, las escalas y otras transformaciones que aprenden de los datos deben obtenerse con entrenamiento. Esto no impide hacer un análisis puramente descriptivo del conjunto completo cuando no se pretende evaluar un modelo.

Un EDA puede terminar en una comunicación de resultados, en la necesidad de recoger información adicional o en una preparación para una etapa posterior. No obliga a entrenar un modelo.

17. Guía de lectura y conceptos esenciales

Gráfico	Lectura principal	Error que conviene evitar
Histograma	Concentración, dispersión, colas y posibles picos.	Confundir intervalos con categorías o ignorar la anchura de los intervalos.
Boxplot	Mediana, IQR, bigotes y puntos separados.	Interpretar los puntos como errores o los bigotes siempre como mínimo y máximo.
Dispersión	Dirección, forma y variación de una nube.	Confundir asociación con causalidad o poca relación lineal con ausencia de relación.
Mapa de calor	Valor de cada cruce según una escala de color.	Interpretar colores sin leyenda o una ausencia como cero.
Barras	Cantidades o proporciones por categoría.	Comparar porcentajes sin saber sobre qué total se calculan.

Vocabulario mínimo

Distribución: reparto de los valores. **Frecuencia:** número de observaciones. **Mediana:** centro de los datos ordenados. **Cuartiles:** posiciones del 25 % y 75 %. **IQR:** distancia entre Q1 y Q3. **Atípico:** caso poco habitual según un criterio. **Correlación:** medida de asociación; Pearson resume la parte lineal.

Una lectura completa de cualquier gráfico

Identificar variables, unidades y población representada. Leer ejes, escalas y leyendas. Localizar el patrón y sus excepciones. Conocer cuántos casos participan. Expresar la conclusión junto a sus límites, sin atribuir al dibujo información que no muestra.

Referencias

NIST. Introducción al análisis exploratorio de datos.

NIST. Histogramas.

NIST. Diagramas de caja y bigotes.

NIST. Gráficos de dispersión.

Seaborn. Mapas de calor.